

Executive Summary

1,000 篇 GLP-1 摘要：前處理如何改變詞頻與檢索設計

2026-10-03 圖表與作業解答更新 | Biomedical IR Homework 2 | 固定 PubMed 英文摘要快照

結論：以基本切詞→標點處理→停用詞→Porter四組比較，詞彙量及索引負擔皆會改變。詞頻呈現高頻集中與長尾，但高 R^2 不能證明所有排名服從同一個 power law。

資料與方法。查詢 GLP-1 / glucagon-like peptide-1、英文、有摘要及截至 2026-09-29 的出版日期；保存 1,200 候選，下載 1,100 筆，納入 1,000 唯一、非空摘要；排除 5 筆，另 195 筆不需納入。只分析摘要正文。四組依序為A基本空白切詞、B沿用HW1 tokenizer處理標點、C移除固定停用詞、D NLTK Porter；介面預設A。各條件共用 NFC / casefold 正規化，B保留 GLP-1、小數及支援的內部撇號，不加入搜尋特徵展開。

條件	Tokens	Unique terms	全範圍 exponent	R^2
A	244,477	29,203	1.081025	0.955040
B	246,256	17,910	1.278303	0.971602
C	179,304	17,792	1.235926	0.965673
D	179,304	14,305	1.304093	0.966623

RQ1-RQ2 | Zipf 是局部近似。以 $\log(CF)=a-b\times\log(rank)$ 作 OLS ($\log$ 以 10 為底)，同頻依詞序給 ordinal rank。四組中頻段的 R^2 最高、RMSE 最低；B 中頻 $b=1.047878$ ，全範圍為 1.278303。殘差仍有系統性彎曲與低頻平台，不能只用 R^2 證明定律。

RQ3 | 超出教科書的觀察。B→C 只移除實際出現的 118 種停用詞，卻刪除 66,952 tokens (27.188%)；C→D 不減 tokens，詞彙再少 19.599%。 ΣDF 從 B 的 152,375 降至 D 的 121,831，是 postings 規模代理量，不是壓縮 bytes 或搜尋效能提升。

RQ4-RQ5 | CF、DF 與 TF-IDF 各有用途。semaglutide 的 $CF=649$ 、 $DF=228$ 、 $IDF=\log(1000/228)=0.642065$ ；and 的 $DF=997$ 、 $IDF=0.001305$ 。CF 表示累積使用，DF 表示文件覆蓋，TF-IDF 結合文件內重複與區辨性。字典、長 postings、gap encoding 與停用詞策略需分別評估，保留否定詞及生醫名稱。

系統成果。Streamlit 保留搜尋與高亮，新增比較、Zipf、近鄰及可選拼字建議。Skip-gram 使用 10,843 句、246,256 個有序 tokens；100 維、window=5、min_count=2、epochs=30、seed=42、workers=1，模型詞彙 9,658。GLP-1 可直接查單詞近鄰；拼字採 Levenshtein DP 與 CF 排序，保護已知詞、數字及縮寫，不默改查詢。

驗證與界線。2026-10-03 完整回歸 497 項通過 (58.18 秒)；21 份分析輸出重跑逐位元一致；39 詞 CF / DF / IDF、16 個回歸及模型離線重載通過。單領域、日期排序樣本與切詞規則限制外推，近鄰不是語意正確率。Porter 由 NLTK 提供，是否課程要求自行實作仍待確認。

來源：HW2_REPORT.md；experiment/summary.json；model/metadata.json；formal-verification.json；tokenizer_verification.json。摘要 SHA256 前 16 碼：9738b68d03a6e39b。