

Biomedical IR Homework 2：1,000 篇 GLP-1 摘要的詞頻、Zipf 與檢索分析

語料取得：2026-09-29；作業四條件版更新：2026-09-30；圖表與解答更新：2026-10-03。固定 1,000 篇 PubMed 英文非空摘要；分析中的 log 統一以 10 為底。依作業要求比較 **A：基本切詞與正規化** → **B：標點處理** → **C：移除停用詞** → **D：Porter**，四組均為正式實驗條件；介面預設顯示 A。所有數值來自本版正式執行，合成資料只用於手算測試。本報告回答 9/29 詳細版 RQ1-RQ5，並保留 9/22 原題的 Word2Vec 與拼字校正。

主要發現：停用詞移除減少 27.188% tokens，Porter 再減少 19.599% 詞彙。四組皆呈現少數高頻詞與大量稀有詞；中頻段的 R^2 最高、log-space RMSE 最低。B 中頻 exponent=1.047878，全範圍則為 1.278303，不能用一條直線與高 R^2 宣稱「證明 Zipf's Law」。

1. 語料、範圍與來源

正式快照位於 [glp1-1000-20260929](#)。查詢式完整保存如下，依 PubMed pub date 排序選取前 1,000 篇符合納入規則的紀錄：

```
("GLP-1"[Title/Abstract] OR "glucagon-like peptide-1"[Title/Abstract])
AND english[Language] AND hasabstract
AND ("1900/01/01"[Date - Publication] : "2026/09/29"[Date - Publication])
```

下載開始時間為 2026-09-29T01:50:15.695115+00:00，完成時間為 2026-09-29T01:50:43.670501+00:00。這是依主題與日期排序取得的目的性樣本，不是全部 PubMed 或一般英文的隨機代表樣本。查詢可在標題命中，但統計內容只取 Article/Abstract/AbstractText 正文；文章標題、結構化摘要小標題及全文均不計入。

取得與篩選項目	實際數量
查詢符合總數	30,622
保存候選 PMID	1,200
已下載紀錄	1,100
正式納入唯一 PMID、英文非空摘要	1,000
排除	5
排除原因：不支援的 PubmedBookArticle	2
排除原因：空摘要	3
已下載且合格，但名額已滿	95
名額已滿而不需下載	100
重複候選 PMID / 重複回傳紀錄	0 / 0

not_needed=195 是 95 篇合格未選加 100 篇未下載，不應和 5 篇排除混為一談。逐篇納排結果在 [selection.json](#)，原始 API 回覆在快照下 raw-batches。兩篇 BookArticle 的排除理由曾由「EFetch 未回傳」更正為「格式不支援」；更正前 metadata 與稽核紀錄仍保留，正文及納入 PMID 不變。另有兩篇文章的期刊卷期年份為 2027，但電子發表日期為 2026、符合 PubMed 日期查詢；不可只以 Document.year 誤判違反截止日期。

摘要 JSONL SHA256：9738b68d03a6e39bed010803aa878cfdc66e0bbcaf005e8ee83d3bcfeb7b2631。分析用 PMID / 摘要文字序列 SHA256：f990854805c5951c6b386ab5071c0ae9eb3630dedc5f4dd0cc9b9b7ea11b9e4a。前者驗證檔案，後者驗證真正送入分析的內容。可增刪的搜尋文章庫與此固定實驗快照分開。

本次未使用 API key；程式單線每秒最多 1 request、每批 100 PMID、暫時錯誤最多 3 次嘗試，保存快取供失敗續傳。官方無 key 限制為每秒 3 requests，參見 [NCBI E-utilities 使用規範](#) 與 [NCBI API key 說明](#)。tool=ir_hw2；未提供聯絡 email，沒有虛構註冊資料。原始 PubMed 摘要可能受著作權保護，本地課程分析保存不代表所有摘要皆為開放授權。

2. 作業四條件 A → B → C → D

四個條件共同呈現基本切詞、標點處理、停用詞與 stemming 的累積效果。各組從同一份原始摘要建立；A 與 B 共用 HW1 正規化，B 直接沿用原 tokenizer，不將 A 的 token 清單重新拼接。

條件	本次實作與可重現定義
A：基本切詞	空白切分，每個 token 呼叫 HW1 normalize；保留附著及獨立標點。
B：標點處理	直接呼叫 <code>ir_hw1.preprocessing.tokenize(text)</code> 取每個 <code>Token.term</code> ，沿用原 regex 及 normalize，不重寫切詞規則。
C	B 再移除固定 132 詞的 <code>hw2-function-words-v1</code> ；保留 no、not、without。本語料實際出現其中 118 種。
D	C 再直接呼叫 <code>HW1 stem_term</code> ；只對純 ASCII 字母使用 NLTK Porter <code>MARTIN_EXTENSIONS</code> ，複合詞、小數、撇號詞及非 ASCII token 保留。

共同正規化為 NFC、Unicode casefold，並將 ' 轉為 '，- / - 轉為 -。B 原切詞規則保留內部支援的連字號、撇號、數字及小數，因此 GLP-1、IL6、3.5、β-cells 分別成為 `glp-1`、`il6`、`3.5`、`β-cells`；`patient's` 成為 `patient's`。casefold 包含一般大小寫統一，另可將 `Straße` 變成 `strasse`；不是只對 ASCII 使用 lower。

以 The patients GLP-1 improved 3.5 mg. 為例：

條件	有序 tokens
A	the, patients, glp-1, improved, 3.5, mg. (最後一詞保留句點)
B	the, patients, glp-1, improved, 3.5, mg
C	patients, glp-1, improved, 3.5, mg
D	patient, glp-1, improv, 3.5, mg

逗號只用來分隔表中各 token。這個小例子用來解釋規則，正式數值全部取自 PubMed 快照。B 保留停用詞，C / D 按上述順序累積；沒有搜尋用的 `IL6` → `il-6` / `il / 6` 特徵展開，沒有額外孤立字母、數字或生醫詞過濾，也沒有 stemming 後再刪一次停用詞。

每個 PMID 算一篇 document；同篇同詞重複出現仍只增加一次 DF。即使某篇 C / D tokens 全被移除，N 仍保留該篇。重複 PMID、無效 PMID 或空摘要明確報錯。

分析版本 `hw2-hw1-four-conditions-v5-log10`；原切詞版本 `unicode-word-v1`。baseline_tokenizer_spec() 保存實作、regex、NFC / casefold 規則、原始碼與依賴指紋，不含分析版本或 log 底數。原 `ir_hw1/preprocessing.py` SHA256 為 `f7108e87d1c19c43e012836adcb6d8b429e4d06c5cdc2bead4a06f71f04919c2`，本次未修改。停用詞表 SHA256 為 `d907482b2aabc0443ae05c95e0c9685ef6f8ff8789370a34c004a498d1abc406`。Python 3.13.14、NLTK 3.9.2、regex 2026.9.10、Matplotlib 3.11.2；完整設定及分析程式指紋見 [summary.json](#)。

Porter 明確沿用 NLTK 的 Martin 擴充模式，不是自行撰寫 Porter 演算法；模式定義參見 [NLTK 官方文件](#)。先前全符號拆詞的對數實驗、模型、報告與 PDF 已封存於 `reports/hw2/history/unicode-split-log10-20260930/`，不與本版數值混用。


3. 詞彙與高頻詞：RQ3

條件	Documents	Tokens	Unique terms	平均 tokens / 篇	CF=1 詞數	CF=1 / 詞彙	Top 10 / tokens	ΣDF
A	1,000	244,477	29,203	244.477	17,363	59.456%	18.012%	162,028
B	1,000	246,256	17,910	246.256	8,252	46.075%	17.950%	152,375
C	1,000	179,304	17,792	179.304	8,248	46.358%	5.730%	128,458
D	1,000	179,304	14,305	179.304	6,847	47.864%	6.844%	121,831

單字數以各條件 tokens 為準，不沿用 HW1 介面顯示的空白字數。ΣDF 是不含位置的「詞-文件」postings entry 數量，可作索引大小的代理量，並非實際壓縮 bytes。

條件	依排名列出的 Top 10 (括號為 CF)
A	and (10,586), the (6,144), of (5,807), in (4,864), with (4,126), to (3,567), a (3,105), for (2,255), were (1,867), was (1,713)
B	and (10,658), the (6,149), of (5,808), in (4,871), with (4,132), to (3,572), a (3,150), for (2,257), were (1,870), glp-1 (1,736)
C	glp-1 (1,736), receptor (1,171), patients (1,096), weight (1,032), risk (968), obesity (959), diabetes (845), 95 (838), metabolic (823), agonists (807)
D	glp-1 (1,736), us (1,446), studi (1,262), patient (1,252), receptor (1,223), agonist (1,121), risk (1,075), weight (1,071), associ (1,046), obes (1,040)


完整 Top 50 見 A、B、C、D；terms_A.csv 至 terms_D.csv 保存全部 rank、CF、DF 與 IDF。



A-D 四條件的計數、詞彙及索引代理量

讀圖先看 A 與 B：附著標點等表面詞型減少；再比較 B 與 C：tokens 柱變短，表示刪除常見功能詞；再看 C 與 D：tokens 柱一樣高，但詞彙柱變短，表示詞型合併。不同圖框各有單位，不能直接比較不同圖框的柱高。

High-frequency words: Top 10 in each condition



A-D Top 10 高頻詞並排比較；四圖共用 CF 尺度

高頻詞圖直接比較「哪些詞」以及「出現幾次」。A / B 的 and、the、of 等功能詞占據前列；C 移除停用詞後，以 glp-1、receptor、patients 等為主；D 再呈現 patient、studi 等合併後的 stem。各組獨立排名，因此同一列不表示同一個詞。附錄完整列出 A-D 各 50 詞，離線閱讀 PDF 也能查看。

A → B：原 tokenizer 處理標點後，表面詞型減少。Tokens 增加 1,779 (0.728%)，詞彙減少 11,293 (38.671%)；例如 data, 與 data. 可合成 data。原切詞也可能拆開斜線等未保留的分隔字元，因此 token 總數略增。GLP-1 及 3.5 仍完整保留，不能把這次變化說成拆開它們的結果。單次詞比例由 59.456% 降至 46.075%；這是表面差異減少的整體現象，未對每個稀有詞做因果歸因。

B → C：少量詞型承擔大量出現次數。移除 118 種實際出現的停用詞，只減少 0.659% 詞彙，卻刪除 66,952 tokens (27.188%)； ΣDF 減少 23,917 (15.696%)。Top 10 的份額由 17.950% 降至 5.730%，高頻端轉向 glp-1、receptor、patients 等領域詞。全範圍 exponent 由 1.278303 降至 1.235926，高頻段由 0.805420 降至 0.561696；移除停用詞不等於自動更符合 Zipf。

C → D：stemming 合併詞型，不刪除 token。Tokens 保持 179,304，詞彙由 17,792 降至 14,305 (減少 19.599%)； ΣDF 再減少 6,627 (5.159%)。不同詞型可能出現在同一文件，合併後的 DF 不能直接相加。D 的 us 由 use (632)、using (534)、used (262)、useful (10)、uses (8) 合併成 1,446 次；原代名詞 us 已於 C 移除。這說明先停用詞、後 stemming 可產生表面上像停用詞的 stem，本次未追加第二輪過濾。詞型減少不直接證明搜尋品質改善。

4. Zipf 方法、全範圍與分段結果：RQ1、RQ2


每個條件依 CF 遞減、同頻依 Unicode 詞彙順序穩定排序，給予 ordinal rank 1...V，不共用排名或取平均排名。包含所有 CF=1 詞。令 $x = \log(\text{rank})$ 、 $y = \log(CF)$ ，OLS 擬合 $y = a + \text{slope} \times x$ ，Zipf exponent $b = -\text{slope}$ ，即 $CF \approx 10^{a + \text{rank} \times (-b)}$ 。所有 log 底數皆為 10。

$R^2=1-\Sigma(y-\hat{y})^2 / \Sigma(y-\bar{y})^2$; $RMSE=\sqrt{[\Sigma(y-\hat{y})^2 / n]}$ 。RMSE 在 **log(CF)** 空間，分母為 n ，不是 $n-2$ ，也不是原始 CF 空間。頻率相同而 y 無變異時 $R^2=null$ ；少於兩點或 rank 不變不回報不存在的擬合參數。

預先分段：高頻為前 $\text{floor}(1\% \times V)$ 名，中頻為其後至 $\text{floor}(10\% \times V)$ ，低頻為其餘 90%。極小測試另有最少兩點防呆；本次正式資料未觸發調整。各條件相同百分位不是同一組詞，CF 門檻也未必相同。


條件 / 區段	Rank 範圍	n	slope	intercept a	exponent b	R ²	RMSE log(CF)
A 全部	1-29,203	29,203	-1.081025	4.656952	1.081025	0.955040	0.101757
A 高頻	1-292	292	-0.844574	4.099240	0.844574	0.995932	0.022579
A 中頻	293-2,920	2,628	-1.065766	4.701534	1.065766	0.996408	0.016324
A 低頻	2,921-29,203	26,283	-0.974950	4.209155	0.974950	0.865330	0.098173
B 全部	1-17,910	17,910	-1.278303	5.318048	1.278303	0.971602	0.094762
B 高頻	1-179	179	-0.805420	4.087154	0.805420	0.992643	0.028555
B 中頻	180-1,791	1,612	-1.047878	4.685842	1.047878	0.996451	0.015952
B 低頻	1,792-17,910	16,119	-1.380549	5.719645	1.380549	0.947962	0.082557
C 全部	1-17,792	17,792	-1.235926	5.142569	1.235926	0.965673	0.101039
C 高頻	1-177	177	-0.561696	3.481014	0.561696	0.957182	0.048905
C 中頻	178-1,779	1,602	-0.990683	4.475025	0.990683	0.995123	0.017718
C 低頻	1,780-17,792	16,013	-1.357293	5.618940	1.357293	0.946702	0.082201
D 全部	1-14,305	14,305	-1.304093	5.284516	1.304093	0.966623	0.105044
D 高頻	1-143	143	-0.528432	3.513326	0.528432	0.952205	0.048316
D 中頻	144-1,430	1,287	-1.103262	4.795798	1.103262	0.991926	0.025380
D 低頻	1,431-14,305	12,875	-1.376586	5.559078	1.376586	0.940850	0.088105

完整精度見 [regression.csv](#)。表格四捨五入僅為閱讀；後續運算使用完整數值。




不同前處理方法的詞頻排名分布（Y 軸為對數刻度）

圖 1：為同時呈現高頻詞與低頻長尾的分布，本圖採用對數詞頻軸，比較各前處理方法的影響。橫軸是線性排名，1 是最常見詞；縱軸是出現次數 CF，以 10 為底的對數刻度呈現，主要刻度依序為 1、10、100、1,000。底部平台代表詞彙出現 1 次，不是 0 次；曲線越往右延伸，代表不同詞彙越多。圖例直接列出 $A \rightarrow B \rightarrow C \rightarrow D$ 的累積處理方式。



以 10 為底的對數 Zipf 散點與全範圍 OLS

圖 2：兩軸都取 log，橫軸增加 1 表示 rank 增加十倍；縱軸增加 1 表示 CF 增加十倍。彩色點是實測詞頻，黑色實線是全範圍回歸。若 $b=1$ ，排名變十倍，預測頻率就變成十分之一。中段較接近直線，但頭尾有偏離；A 的全域 b 最接近 1，也不代表它是最佳文字處理方式。




全範圍 OLS 殘差

圖 3：縱軸為「觀察 $\log(\text{CF})$ - 全範圍預測 $\log(\text{CF})$ 」，0 表示相符，負值表示實際頻率比直線預測低。虛線標記區段邊界，並非回歸線。四組皆有系統性彎曲，B-D 頭部尤其被全域直線高估；尾端整數 CF 形成斜帶。這不是各段重新擬合後的殘差。

RQ1：是否符合 Zipf？ 可描述為 Zipf 式的不均勻詞頻，以及中頻區段的良好局部近似；不能宣稱所有 rank 服從同一精確 power law。結論同時使用圖形、分段 slope、 R^2 、RMSE 與殘差。

RQ2：exponent 是多少？ 必須連同處理方式及區間回答。A-D 全範圍依序為 1.081025、1.278303、1.235926、1.304093；主要基準 B 的中頻 $b=1.047878$ ，不能拿它替代 B 全範圍的 1.278303。

哪段最好？ 在預先指定的三段中，四組中頻均同時具有最高 R^2 、最低 RMSE， b 介於 0.990683-1.103262。B 中頻 $R^2=0.996451$ 、RMSE=0.015952，C 中頻 $b=0.990683$ 最接近 1；「最接近 $b=1$ 」與「 R^2 最高」並非同一指標。各段 x/y 範圍不同，跨段 R^2 並非完全等價，這仍是描述性比較。



A-D 各三段分別回歸：R² 與 RMSE 並排比較

每組三根柱依序為高頻、中頻、低頻。左圖看 R² 越高，右圖看 log(CF) RMSE 越低；本次四組都由中頻同時取得這兩項最佳值。兩個指標單位不同，需分別讀各自縱軸；即使 R² 柱高很接近，右圖仍能看出殘差量級的差異。

R² 是否充分？ 不充分。排序後的 rank / CF 不是獨立隨機觀測；OLS 對各詞型同權，長尾占多數；同頻詞分配不同 ordinal ranks 會形成平台。高 R² 只表示指定 log 空間的線性解釋程度，沒有比較替代分布、估計 cutoff 不確定性或完成 power-law 適合度檢定。若只挑 CF=1 平台，水平線 RMSE=0，但 R² 無定義、b=0，更不能當成理想 Zipf。本次沒有冒稱完成這些延伸統計證明。

5. CF、DF 與指定 IDF：RQ4

CF(t)=所有摘要中 t 的出現次數；DF(t)=包含 t 的不同 PMID 數。指定公式為 $IDF(t)=\log(1000 / DF(t))$ ，不平滑、不加 1；HW1 搜尋的 $\ln((N+1)/(DF+1))+1$ 僅用於既有搜尋。

B 條件選出 39 個實際觀察的 terms：前 10 名、固定排名百分位，以及存在的領域 / 否定詞，涵蓋高、中、低頻。包含完整 glp-1、glp-1ra、peptide-1、 β -cells、il6；數字及符號樣式也照實列出，沒有為美化結果而臨時過濾。兩表合計滿足至少 20 詞 CF / DF 及至少 10 詞 IDF 的要求。


5.1 選詞表 (1 / 2)

B term	CF	DF	IDF=log(1000 / DF)
and	10658	997	0.001305
the	6149	977	0.010105
of	5808	972	0.012334
in	4871	961	0.017277
with	4132	915	0.038579
to	3572	943	0.025488
a	3150	922	0.035269
for	2257	860	0.065502
were	1870	570	0.244125
glp-1	1736	574	0.241088
receptor	1171	793	0.100727
patients	1096	405	0.392545
obesity	959	466	0.331614
diabetes	845	529	0.276544
glucagon-like	751	695	0.158015
treatment	744	412	0.385103
peptide-1	691	644	0.191114
semaglutide	649	228	0.642065
not	572	366	0.436519
glp-1ra	490	140	0.853872

5.2 選詞表 (2 / 2)

B term	CF	DF	IDF=log(1000 / DF)
insulin	431	194	0.712198
glp-1ras	421	161	0.793174
no	328	242	0.616185
glucose	326	155	0.809668
agonist	312	245	0.610834
without	245	176	0.754487
strategies	185	145	0.838632
because	67	53	1.275724
gaps	40	35	1.455932
play	18	18	1.744727
β-cells	8	7	2.154902
emphasized	7	7	2.154902
glp	7	6	2.221849
militaris	4	2	2.698970
152	2	2	2.698970
il6	2	1	3.000000
pathway-specific	2	2	2.698970
endotyping	1	1	3.000000
8	1	1	3.000000

可重用表格：CF / DF CSV、IDF CSV。例如 semaglutide 的 $IDF = \log(1000 / 228) = 0.642065$ ，and 的 $IDF = \log(1000 / 997) = 0.001305$ 。




B 條件 39 個選詞的 CF / DF 散點圖

兩軸採 log 刻度，每一點代表一個選詞；相同座標的詞會重疊。虛線 $CF=DF$ 表示命中的每篇文件恰好出現一次；同一 DF 下，點越高表示文件內重複更多。這是指定選詞的比較，不是全體詞彙的分布估計。

高 CF、相對低 DF 為何出現？ 同篇文章可重複使用藥名，CF 增加但 DF 只加一次。semaglutide 出現 649 次、分布在 228 篇，命中文章平均約 2.85 次，覆蓋率 22.8%。這是局部重複及主題聚集，不表示每篇都重要。il6 的兩次集中於一篇，endotyping 只有一次，但兩者 $DF=1$ ，IDF 同為 3。


哪個量表示分布廣度？ DF 或 DF/N ，直接表示文件覆蓋。 β -cells 的 $CF=8$ 、emphasized 的 $CF=7$ ，但 DF 同為 7，IDF 同為 2.154902；反過來，il6 與 pathway-specific 的 CF 都是 2，DF 分別 1、2，IDF 分別 3、2.698970。這些實例說明不能用 CF 取代 DF。

為何兩者都重要？ CF 描述累積使用與 token 負擔，DF 對應 postings 文件覆蓋及 IDF，TF 保留個別文件重複程度。高 CF 不必然代表低 IDF；低 DF 的高 IDF 也可能來自錯字、數字或狹窄概念，不能直接當成相關性標籤。本次沒有人工 relevance judgments，未宣稱檢索準確率提升。



文件覆蓋數 DF 與指定 IDF 的關係；N=1,000

橫軸為 DF 的 log 刻度，縱軸直接表示 IDF，未再取一次 log。灰線是 $IDF = \log(N / DF)$ 的公式，綠點取自上表。DF 越接近 N，IDF 越接近 0；DF=1 時 IDF=3。這裡的低 IDF「常見詞」指廣泛存在於多篇文件，不能只由高 CF 判斷。



12 個代表詞的 IDF 與對應 DF

and 幾乎出現於全部文件，因此 IDF 很低；semaglutide 覆蓋 228 篇，IDF 較高。il6 與 pathway-specific 同為 CF=2，DF 分別為 1 與 2，所以 IDF 不同。TF-IDF 再結合各文件內的 TF，降低廣泛常見詞的權重；這張圖只展示 IDF，沒有把 CF 當成某篇文件的 TF。

6. IR 意義與 technical argument : RQ5

B 前 10 個詞占 17.950% tokens ; 另一端 8,252 個單次詞占 46.075% 詞彙，卻僅占 3.351% tokens。字典長尾與常見詞長 postings 的成本來源不同，不能僅靠 tokens 或 vocabulary 一個數字描述全部儲存。

B→C 的 ΣDF 從 152,375 降至 128,458，表示移除常見詞可縮減 postings 的潛在負擔；本次未量測壓縮 bytes 或比較查詢延遲。高 DF 詞通常有較短 docID gaps，可考慮 gap encoding / 變長整數；稀有詞則有字典與短清單開銷，可考慮字典前綴壓縮、分塊等。實際收益取決於文件排列、編碼與位置資訊，不能由 exponent 單獨預測。

TF-IDF 以文件內 TF 表示重複、以 IDF 表示跨文件區辨性；單看 CF 排名不足以替代。保留否定詞能減少語意損失，但沒有最佳停用詞表的普遍保證。Word2Vec 或拼字候選也不能把高頻等同正確。Zipf 即使只是近似，仍可協助容量估計、字典與 postings 分工、熱門詞快取與停用詞政策。

本次 A→B 顯示標點處理的影響，B→C 顯示停用詞效果，C→D 顯示 stemming 合併；各組均不混入搜尋特徵展開。**token 定義、處理順序與固定語料都是研究結論的一部分。**實驗揭示工程取舍，沒有宣稱改善人工標註的檢索品質。

English discussion: Why does Zipf's Law matter to IR?

Zipf's law matters to information retrieval because vocabulary and occurrences impose different costs. In this fixed collection of 1,000 GLP-1 abstracts, the original HW1 tokenizer produces 246,256 tokens and 17,910 distinct terms in condition B. Its ten most frequent terms account for 17.950 percent of occurrences, while 8,252 terms occur only once. An average term cannot adequately describe both the concentrated head and the substantial vocabulary tail.

Stopword removal makes this distinction concrete. Moving from B to C removes 118 observed types, only 0.659 percent of the vocabulary, but removes 66,952 occurrences, or 27.188 percent of tokens. This can reduce processing and storage associated with frequent words. It does not establish better retrieval effectiveness: common words support phrases, and negation changes biomedical meaning. Our fixed stoplist therefore preserves no, not, and without. Porter stemming subsequently reduces vocabulary by 19.599 percent without reducing token counts, but merging forms may also obscure meaningful distinctions.

An inverted index represents both a dictionary and postings. Rare terms enlarge the dictionary even when their lists are short. Common terms create longer lists and can increase query processing costs. Removing stopwords reduces term-document postings from 152,375 to 128,458 in this experiment. These counts are storage proxies, not measured compressed bytes. Encoding sorted document identifier gaps, using variable-length integers, and compressing dictionary prefixes can exploit regularities. Actual savings still depend on document ordering, representation, and whether positions are stored.

TF-IDF addresses discrimination across documents. Under the assignment formula, and has DF 997 and IDF 0.001305, whereas semaglutide has DF 228 and IDF 0.642065. Repetition within relatively few documents can produce high CF without high DF. For example, il6 and pathway-specific each occur twice, but their document frequencies differ. Frequency ranking therefore cannot replace document-frequency weighting, and high IDF alone does not guarantee relevance or correctness.

Finally, Zipf provides an engineering approximation rather than a universal proof. Condition B has a full-range exponent of 1.278303 and a middle-segment exponent of 1.047878. Residual curvature and discrete tail plateaus remain despite high R-squared values. Keeping GLP-1 and decimal numbers intact makes the token contract explicit; it does not remove every linguistic ambiguity. Fixed snapshots, shared tokenizer provenance, and separate search features support reproducible comparisons. The practical lesson is to anticipate uneven resource demands and evaluate design choices with measurements while preserving distinctions that a convenient statistical model might hide.

英文段落按兩個標記間正文的空白分割機器計數為 **389 words**，符合 300-500 words，不包含標題或本句。正文與字數在交付核對時由 `scripts/verify_hw2_delivery.py` 檢查，輸出至 `reports/hw2/analysis_verification.json`。

7. Word2Vec : 正式模型與探索性近鄰

本版沿用保存的 B 條件模型，原切詞契約、語料與有序句子完全相同，重新驗證離線重載，沒有再次訓練。模型採 Gensim Skip-gram with negative sampling，以中心詞預測周邊詞；沒有與 CBOW 做本次比較，不能宣稱更優。每篇摘要沿原始 block、句子及 B token 順序訓練，不由排序詞頻或 postings 重建句序；上下文不跨文件、摘要 block 或偵測句子邊界。API 參見 [Gensim 官方 Word2Vec 文件](#)。

正式訓練項目	實際設定 / 結果
Documents / sentences / ordered tokens	1,000 / 10,843 / 246,256
算法	sg=1 ; negative=5 ; hs=0 (Skip-gram 負採樣)
vector_size / window / min_count	100 / 5 / 2
epochs / seed / workers	30 / 42 / 1
sample / ns_exponent	0.001 / 0.75
alpha → min_alpha	0.025 → 0.0001
shrink_windows / sorted_vocab	true / 1
模型詞彙	9,658
訓練耗時	17.7362 秒 (保存模型的原訓練，本版未重訓)
Gensim / NumPy / SciPy	4.4.0 / 2.5.3 / 1.18.1

9,658 正好等於 B 的 17,910 詞扣除 8,252 個單次詞。保存的句子仍保留全部 B tokens ; Gensim 訓練時另外套用 min_count 與高頻下採樣，不能把輸入 tokens 直接視為有效訓練更新次數。保存檔為 [word2vec.model](#)，[metadata.json](#) 保存 schema=2、原 tokenizer 契約、語料與句序 hash、穩定初始雜湊、平台及參數。缺少或不符 tokenizer 契約的舊模型會被拒絕，提示重新訓練；只改統計 log 底數不會使原切詞契約失效。

本次近鄰前三名如下；cosine 是向量夾角相似度，不是語意正確率：

查詢詞	第 1 近鄰 / cosine	第 2 近鄰 / cosine	第 3 近鄰 / cosine
semaglutide	liraglutide / 0.670418	tirzepatide / 0.660938	dulaglutide / 0.613227
insulin	resistance / 0.742960	secretion / 0.564221	glargine / 0.552639
obesity	overweight / 0.623412	tdt-induced / 0.604472	type-2 / 0.587148
glp-1	ras / 0.696814	ra / 0.686772	hepatotoxicity / 0.644049
liraglutide	dulaglutide / 0.707752	tirzepatide / 0.685940	semaglutide / 0.670418

完整結果見 [neighbors.json](#)。GLP-1 現在是一個完整 B token，與 glp-1 查詢結果相同；GLP-1 receptor 是兩詞，單詞近鄰介面明示 invalid_query；zzzznotincorpus 明示 OOV，不捏造向量。obesity 的 tdt-induced、glp-1 的 hepatotoxicity 等近鄰不能直接當成同義詞或已驗證醫學關係。1,000 篇單主題語料、縮寫斷句與低頻上下文都限制解讀。

正式模型已於封鎖網路的整合驗證中成功重載；vectors SHA256=7de476d45de19d97d0572bbc561266ba6efac538c462a4f817144e647cae62f0，結果見 [formal-verification.json](#)。固定 seed 與單 worker 方便同環境重現；不宣稱跨 BLAS、套件或平台逐位元重訓相同。

8. 拼字建議與介面整合

拼字採動態規劃 Levenshtein edit distance，以正式 B 語料詞彙找候選，依距離升冪、CF 降冪、穩定詞序排序。最多 3 候選、最大距離 2；長度不超過 5 的詞最多距離 1。詞彙與查詢共用 HW1 正規化，版本 hw2-levenshtein-hw1-cf-v2。原查詢與建議並列，使用者明確採用才搜尋；已知詞保留，未知詞不等於錯字，包含數字、非 ASCII、混合大小寫、全大寫縮寫與短詞有保護。

原查詢	實際建議 / 保留結果	檢核重點
semaglutide	原樣保留	known_word ; 正確詞不改寫
semaglutid	semaglutide	距離 1、CF=649
insulinn	insulin	距離 1、CF=431 ; 次選 insulins 距離 1、CF=8 ; inulin 距離 2、CF=6
zzzznotincorpus	保留，標記 unresolved	允許距離內無候選
GLP-1 BRCA1 IL6 HbA1c	整串原樣保留	四詞均為語料已知詞；未知含數字詞亦受保護
Semaglutide treatment	大小寫及原查詢保留	已知詞不額外改寫

正式離線搜尋及原文位置高亮通過：semaglutide 命中 234 篇、insulin 203 篇、obesity treatment 695 篇、GLP-1 580 篇、未知查詢 0 篇。這些是既有 HW1 搜尋規則的命中數，**不等於分析 B 的 DF**；例如 B insulin DF=194，B glp-1 DF=574，搜尋仍可因其既有特徵及處理方式命中不同集合。

Streamlit 保留繁體中文搜尋、文章管理與原文高亮，新增獨立快照的前處理比較、Zipf、近鄰和可選拼字建議。下載、統計及訓練由明確按鈕 / CLI 觸發。UI 會核對分析版本、log 底數與 tokenizer 契約，拼字詞彙快取包含版本及契約，避免同一語料 rerun 沿用舊切詞結果。新版以五個主題與分頁組織圖表：A-D 數量及高頻詞、Zipf 分布 / 回歸 / 殘差 / 區段、CF / DF / IDF、Word2Vec、作業解答與下載。完整數表及管理設定採展開方式，圖表沿用固定條件色；高頻詞寬畫面並排，窄畫面上下排列。2026-10-03 AppTest 與瀏覽器檢查紀錄另存 comparisons-qa；原始 2026-09-29 瀏覽器證據仍屬歷史版本。

9. 正確性、重現與交付檔案

手算測試 tests/test_hw2_analysis.py 實跑 **46 項通過**，涵蓋逐詞對照 HW1、GLP-1 / IL6 / 小數 / Unicode / 撇號、C / D 累積且不額外過濾、CF / DF、IDF $\log(10)=1$ 、DF=N 時為 0、exact power-law、常數 $R^2=\text{null}$ 、少點防呆、摘要隔離與輸出。

最新完整回歸 **497 passed** (2026-10-03，58.18 秒；原 HW1 348 + HW2 149)，零失敗 / 錯誤 / 跳過，紀錄為 reports/hw2/comparisons-pytest.xml。新增測試核對圖表使用的 CF / DF、覆蓋率、區段比較及資料來源；最後字標 / 刻度調整另通過 17 項圖表與 UI 測試。原始基線為 342 passed、6 個缺 Git 歷史 fixture 的 setup errors，沒有 assertion failure。唯讀取出 HW1 歷史版本的 15 份 XML、保存 SHA256 並修復 fixture 可攜性後，原有 348 項通過，未刪除原測試或更改斷言。四組 v5 當時的歷史驗收為 **487 passed in 50.69 seconds = 原有 348 + HW2 139**，零失敗 / 錯誤 / 跳過；紀錄 reports/hw2/pytest-hw1-tokenizer.xml 及 .log。初版 444、log 版本 v2 的 450 均為歷史結果。

```
Set-Location 'C:\成大專案\IR-HW2'
```

```
.\.venv-hw2\Scripts\python.exe -X utf8 -m pytest -q --basetemp tmp/pytest-comparisons-manual  
--junitxml=reports/hw2/comparisons-pytest.xml
```

```
.\.venv-hw2\Scripts\python.exe -X utf8 scripts/verify_hw2_tokenizer.py
```

```
.\.venv-hw2\Scripts\python.exe -X utf8 scripts/verify_hw2.py
```

verify_hw2_tokenizer.py 已離線重新執行正式分析，16 CSV + 1 summary JSON + 4 PNG 共 **21 檔逐位元一致**；核對 1,000 篇各條件有序 tokens、 ΣCF 、DF 範圍、 ΣDF 、Top 50、39 選詞 IDF，並用獨立 NumPy OLS 核對全部 16 個擬合，最大絕對差約 1.954×10^{-14} 。完整結果在 [tokenizer_verification.json](#)。快照 30 個檔案未改動；原 HW1 preprocessing 指紋未改動。四張正式 PNG 保留，另由相同 summary.json 產生五張補充比較圖，保存於 reports/hw2/figures/，來源及程式指紋在 comparison_figures.json；不加入原有 21 檔實驗輸出。九圖均納入本報告，並逐張查看。補充圖重建命令為 python scripts/build_hw2_comparison_figures.py。

重算命令為 `-m ir_hw2.cli analyze`；另存可加 `--output tmp/hw2-tokenizer-manual`。

`scripts/verify_hw2_delivery.py` 在報告 / PDF 重建後整合英文字數、報告數字、模型句序、測試及 PDF manifest，寫出 `analysis_verification.json`；一般分析驗證不必先重建 PDF。

成果	位置 / 用途
固定語料與來源稽核	<code>data/hw2/glp1-1000-20260929/</code> ：原始 XML、PMID、查詢、納排、hash
A-D 統計與比較	<code>reports/hw2/experiment/summary.json</code> 、 <code>preprocessing_comparison.csv</code> / PNG
各條件詞表與 Top 50	<code>terms_A.csv...terms_D.csv</code> 、 <code>top50_A.csv...top50_D.csv</code>
各文件 tokens / 詞彙	<code>documents_A.csv...documents_D.csv</code>
全範圍及分段 Zipf	<code>regression.csv</code> 、 <code>rank_frequency.png</code> 、 <code>log_log.png</code> 、 <code>residuals.png</code>
CF / DF / IDF	<code>cf_df_comparison.csv</code> 、 <code>idf_terms.csv</code>
補充比較圖與來源指紋	<code>reports/hw2/figures/</code> 、 <code>comparison_figures.json</code> ；由保存資料繪製
模型、句子與參數	<code>reports/hw2/model/</code>
可重現與交付核對	<code>tokenizer_verification.json</code> 、 <code>formal-verification.json</code> 、 <code>analysis_verification.json</code>

10. 規格差異、限制與待確認事項

9/22 原題第 1 頁包含 Zipf、Porter、Word2Vec 及拼字校正；9/29 詳細版第 2 頁明確要求約 1,000 篇摘要，未明確取消後兩項，因此皆保留。詳細版第 3-6 頁的 A-D、CF / DF、IDF 及 300-500 words 討論在本文完成；第 8 頁的另外一頁 Executive Summary 分開交付。第 7 頁兩領域比較是 optional，本次未執行。

本版依使用者最新確認恢復課堂 A-D 四條件：A 基本切詞與正規化、B 沿用 HW1 tokenizer 處理標點、C 停用詞、D Porter；各組同等列入比較，所有分析使用 log（以 10 為底）。中途三組試行方法已撤回，不是本次交付現況。語料只有單一主題、按日期排序而非隨機；原 tokenizer 雖保留 GLP-1、小數及支援的內部連字號，仍不是完整生醫實體辨識器，未支援的標點可能切開名稱。Porter 可能過度或不足合併；固定停用詞表不是普遍最佳設定。OLS 是描述性分析，近鄰沒有醫學語意 gold standard，搜尋沒有 relevance judgments；重現僅涵蓋記錄的本機環境。

待確認：教師是否要求自行撰寫 Porter；提交媒介、demo 時長及是否有更新截止日。原題截止日為 2026-10-06。NLTK 套件實作不冒稱手刻，講義延伸也不自動列為必做。

11. 規格與方法來源

1. [Homework-2-26-20260922-1.pdf](#)，第 1 頁：原題範圍、Porter、Word2Vec、拼字校正及截止日期。
2. [project-2-details-20260929-1.pdf](#)，第 1-2 頁：研究目標、約 1,000 篇語料、Zipf；第 3-4 頁：前處理、CF / DF、回歸與區段；第 5-6 頁：指定 IDF 與 IR 意義；第 7-8 頁：optional challenge、technical argument、RQ1-RQ5、一頁摘要。
3. [lecture-2-dictionary-20260922-1.pdf](#)，第 7、10、36-46 頁：字詞與前處理；第 23-35 頁：向量詞表示；第 56-58 頁：Zipf；講義的其他延伸不自動列為必做。
4. NCBI E-utilities 一般說明、參數文件、API key / 速率說明：下載方法與使用限制，查核日 2026-09-29。
5. NLTK PorterStemmer 官方 API：演算法模式；實際安裝版本另見本次 metadata。
6. Gensim Word2Vec 官方 API：有序句子輸入、參數、模型儲存與重現限制；網頁文件版本可能不同於本次安裝的 4.4.0，以本次 metadata 記錄執行版本。

附錄：A-D 各組 Top 50 詞頻

各組依 CF 遞減、同頻依詞序排名；左半為第 1-25 名，右半為第 26-50 名。CF 表示全語料出現次數。其餘全部詞彙及 DF / IDF 另保存在各條件 CSV。

A 條件 Top 50

Rank	Term	CF	Rank	Term	CF
1	and	10,586	26	from	770
2	the	6,144	27	associated	768
3	of	5,807	28	are	750
4	in	4,864	29	glucagon-like	737
5	with	4,126	30	these	719
6	to	3,567	31	peptide-1	675
7	a	3,105	32	95%	657
8	for	2,255	33	2	656
9	were	1,867	34	clinical	654
10	was	1,713	35	agonists	644
11	glp-1	1,222	36	at	636
12	this	1,222	37	obesity	627
13	or	1,181	38	diabetes	625
14	is	1,150	39	treatment	616
15	receptor	1,150	40	not	564
16	as	1,110	41	evidence	555
17	on	1,049	42	may	545
18	by	1,019	43	an	539
19	patients	948	44	study	534
20	weight	939	45	type	533
21	that	926	46	using	531
22	risk	824	47	use	529
23	metabolic	775	48	effects	498
24	we	775	49	semaglutide	488
25	=	770	50	outcomes	481

B 條件 Top 50

Rank	Term	CF	Rank	Term	CF
1	and	10,658	26	metabolic	823
2	the	6,149	27	agonists	807
3	of	5,808	28	ci	782
4	in	4,871	29	from	777
5	with	4,132	30	we	777
6	to	3,572	31	associated	770
7	a	3,150	32	2	769
8	for	2,257	33	outcomes	761
9	were	1,870	34	are	752
10	glp-1	1,736	35	glucagon-like	751
11	was	1,713	36	p	748
12	or	1,371	37	treatment	744
13	this	1,230	38	these	727
14	receptor	1,171	39	peptide-1	691
15	is	1,156	40	clinical	675
16	as	1,112	41	semaglutide	649
17	patients	1,096	42	effects	647
18	on	1,052	43	study	644
19	weight	1,032	44	at	637
20	by	1,019	45	evidence	636
21	risk	968	46	use	632
22	obesity	959	47	studies	595
23	that	933	48	disease	585
24	diabetes	845	49	not	572
25	95	838	50	1	566

C 條件 Top 50

Rank	Term	CF	Rank	Term	CF
1	glp-1	1,736	26	disease	585
2	receptor	1,171	27	not	572
3	patients	1,096	28	1	566
4	weight	1,032	29	type	555
5	risk	968	30	loss	549
6	obesity	959	31	using	534
7	diabetes	845	32	cardiovascular	499
8	95	838	33	therapy	495
9	metabolic	823	34	glp-1ra	490
10	agonists	807	35	including	463
11	ci	782	36	adults	461
12	associated	770	37	insulin	431
13	2	769	38	trials	423
14	outcomes	761	39	included	422
15	glucagon-like	751	40	glp-1ras	421
16	p	748	41	data	417
17	treatment	744	42	ra	415
18	peptide-1	691	43	among	414
19	clinical	675	44	compared	387
20	semaglutide	649	45	review	387
21	effects	647	46	body	372
22	study	644	47	tirzepatide	368
23	evidence	636	48	management	367
24	use	632	49	across	362
25	studies	595	50	potential	362

D 條件 Top 50

Rank	Term	CF	Rank	Term	CF
1	glp-1	1,736	26	diseas	672
2	us	1,446	27	compar	660
3	studi	1,262	28	semaglutid	649
4	patient	1,252	29	evid	644
5	receptor	1,223	30	trial	619
6	agonist	1,121	31	improv	587
7	risk	1,075	32	increas	572
8	weight	1,071	33	not	572
9	associ	1,046	34	type	571
10	obes	1,040	35	1	566
11	effect	1,030	36	remain	561
12	includ	965	37	loss	555
13	outcom	958	38	reduc	538
14	metabol	941	39	adult	500
15	diabet	938	40	cardiovascular	499
16	clinic	841	41	glp-1ra	490
17	95	838	42	review	469
18	therapi	830	43	evalu	467
19	treatment	822	44	control	465
20	ci	812	45	assess	463
21	2	769	46	reduct	446
22	ra	760	47	insulin	439
23	glucagon-like	751	48	manag	432
24	p	748	49	glp-1ras	421
25	peptide-1	691	50	data	417